Computational
Astrophysics

OBSERVATORIO
ASTRONÓMICO
NACIONAL

OBSERVATORIO
ASTRONÓMICO
NACIONAL DE COLOMBIA

Regresión

Dr. rer. nat. Jose Ivan Campos Rozo

Astronomical Institute of the Czech Academy of Sciences
Observatorio Astrónomico Nacional de Colombia - UNAL

March 29, 2026

CONTENIDO

1 Regresión
- Problemas físicos donde usamos regresión
- Regresión lineal sin intercepto
- Regresión lineal generalizada
- Regresión no lineal

Problema del carro "ratonera"

Un estudiante quiere construir un coche con trampa para ratones que vaya más rápido o más lejos.

Se supone que la relación entre el par motor (T) y el ángulo de rotación (θ) es una línea recta:

$$T = k_0 + k_1\theta$$

donde k_1 es la constante elástica.

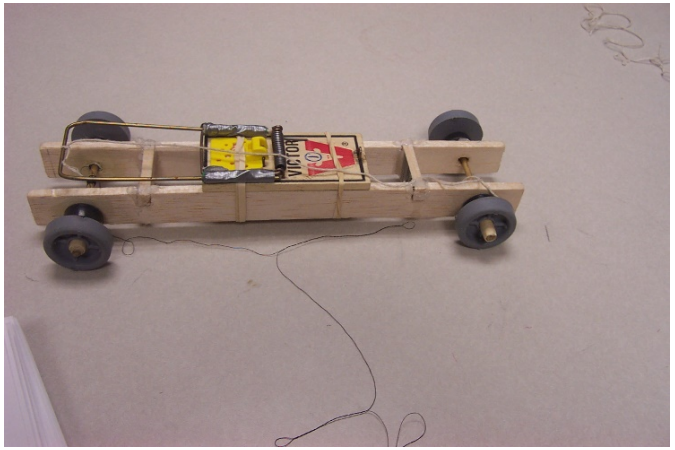

Se mide con instrumentos de laboratorio el torque para diferentes ángulos del resorte de la trampa de ratón y se tiene

Angle	**Torque**
Radians	N-m
0.698132	0.188224
0.959931	0.209138
1.134464	0.230052
1.570796	0.250965
1.919862	0.313707

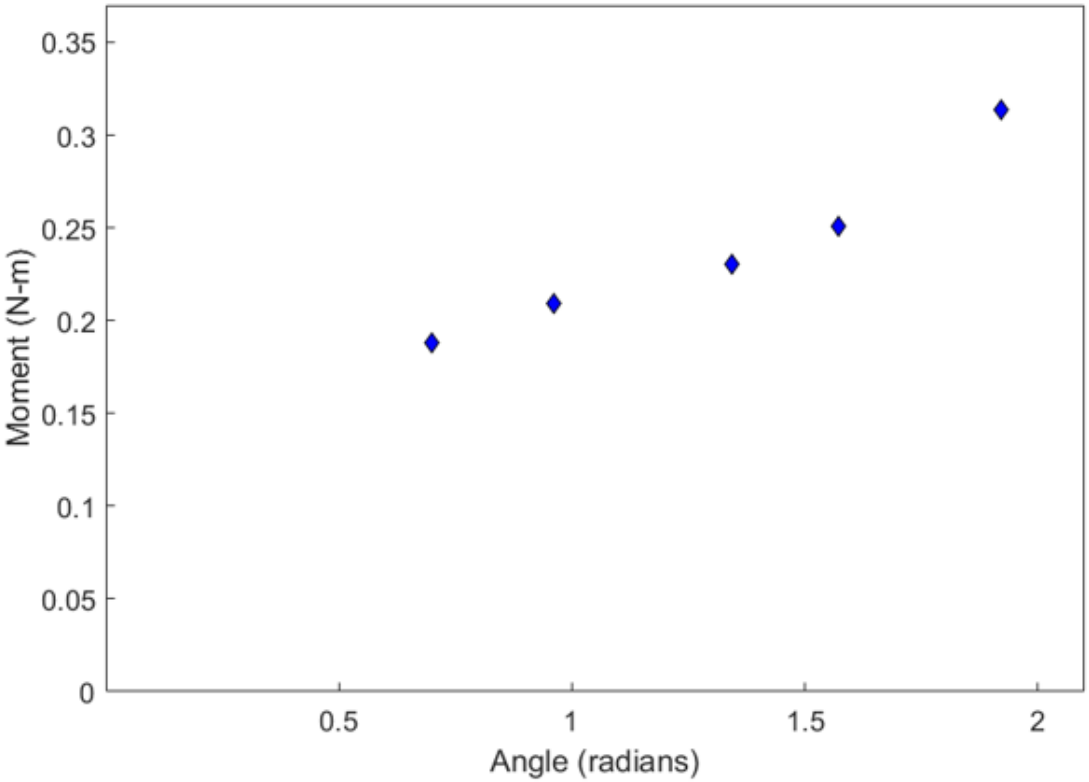

Método de mínimos cuadrados

Para un conjunto dado de n pares de datos $(x_1, y_1), \ldots, (x_n, y_n)$, buscamos ajustar un modelo $y = a_0 + a_1 x$.

El residuo E_i en cada punto de datos es la diferencia entre los valores observados y predichos:

$$E_i = y_i - (a_0 + a_1 x_i) \tag{1}$$

El método de mínimos cuadrados minimiza la suma de los residuos al cuadrado (S_r):

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_i)^2 \tag{2}$$

.

La solución para las constantes a_0 y a_1 están dadas por

$$a_0 = \frac{\sum_{i=1}^{n} y_i \sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} x_i y_i}{n \sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i \right)^2}$$

$$a_1 = \frac{n \sum_{i=1}^{n} x_i y_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n \sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i \right)^2}$$

donde a_0 se puede reescribir como

$$\begin{aligned} a_0 &= \frac{\sum_{i=1}^{n} y_i}{n} - a_1 \frac{\sum_{i=1}^{n} x_i}{n} \\ &= \overline{y} - a_1 \overline{x} \end{aligned}$$

Regresión lineal sin intercepto

Sea el conjunto de datos $(x_1, y_1), \ldots, (x_n, y_n)$, entonces lo ajustamos con el modelo

$$y = a_1 x$$

Una buena medida de ajuste, es decir, qué tan bien $a_1 x$ predice la variable y, es la suma de los cuadrados de los residuos, S_r

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_1 x_i)^2$$

Para encontrar a_1, revisamos para que valor de a_1, S_r alcanza el mínimo absoluto tal que

$$\frac{\mathrm{d}S_r}{\mathrm{d}a_1} = 2\sum_{i=1}^{n}(y_i - a_1 x_i)(-x_i) = -2\sum_{i=1}^{n} y_i x_i + 2a_1 \sum_{i=1}^{n} x_i^2 = 0$$

De ahí tenemos que

$$a_1 = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2} \tag{3}$$

Si se hace un test de la segunda derivada tenemos que

$$\frac{\mathrm{d}^2 S_r}{\mathrm{d}a_1^2} = \sum_{i=1}^{n} 2x_i^2 > 0$$

Asumiendo que todos los valores de x son diferentes de cero, se puede afirmar que a_1, no solo es un mínimo local, sino un mínimo absoluto.

Ejemplo

Hallar el módulo longitudinal de un material compuesto, usando los siguientes datos. Dado que el módulo longitudinal está dado por $\sigma = E\varepsilon$

Deformación	Estrés (Pa)
0.0	0.0
1.83×10^{-3}	3.06×10^{8}
3.6×10^{-3}	6.12×10^{8}
5.324×10^{-3}	9.17×10^{8}
7.02×10^{-3}	1.223×10^{9}
8.67×10^{-3}	1.529×10^{9}
...	...
1.0244×10^{-2}	1.835×10^{9}
1.1774×10^{-2}	2.14×10^{9}
1.329×10^{-2}	2.446×10^{9}
1.479×10^{-2}	2.752×10^{9}
1.5×10^{-2}	2.767×10^{9}
1.56×10^{-2}	2.896×10^{9}

Dada la ecuación (3), tenemos que

$$E = \frac{\sum_{i=1}^{n} \sigma_i \varepsilon_i}{\sum_{i=1}^{n} \varepsilon_i^2} \tag{4}$$

si $n = 12$, entonces

$$\sum_{i=1}^{12} \varepsilon_i^2 = 1.2764 \times 10^{-3}; \ \sum_{i=1}^{12} \sigma_i \varepsilon_i = 2.3337 \times 10^{8},$$

$$E = \frac{\sum_{i=1}^{12} \sigma_i \varepsilon_i}{\sum_{i=1}^{12} \varepsilon_i^2} = \frac{2.3337 \times 10^{8}}{1.2764 \times 10^{-3}} = 1.8284 \times 10^{11} Pa$$

Por lo tanto tenemos que nuestra ecuación de la recta está dada por $\sigma = 1.8282 \times 10^{11}\varepsilon$

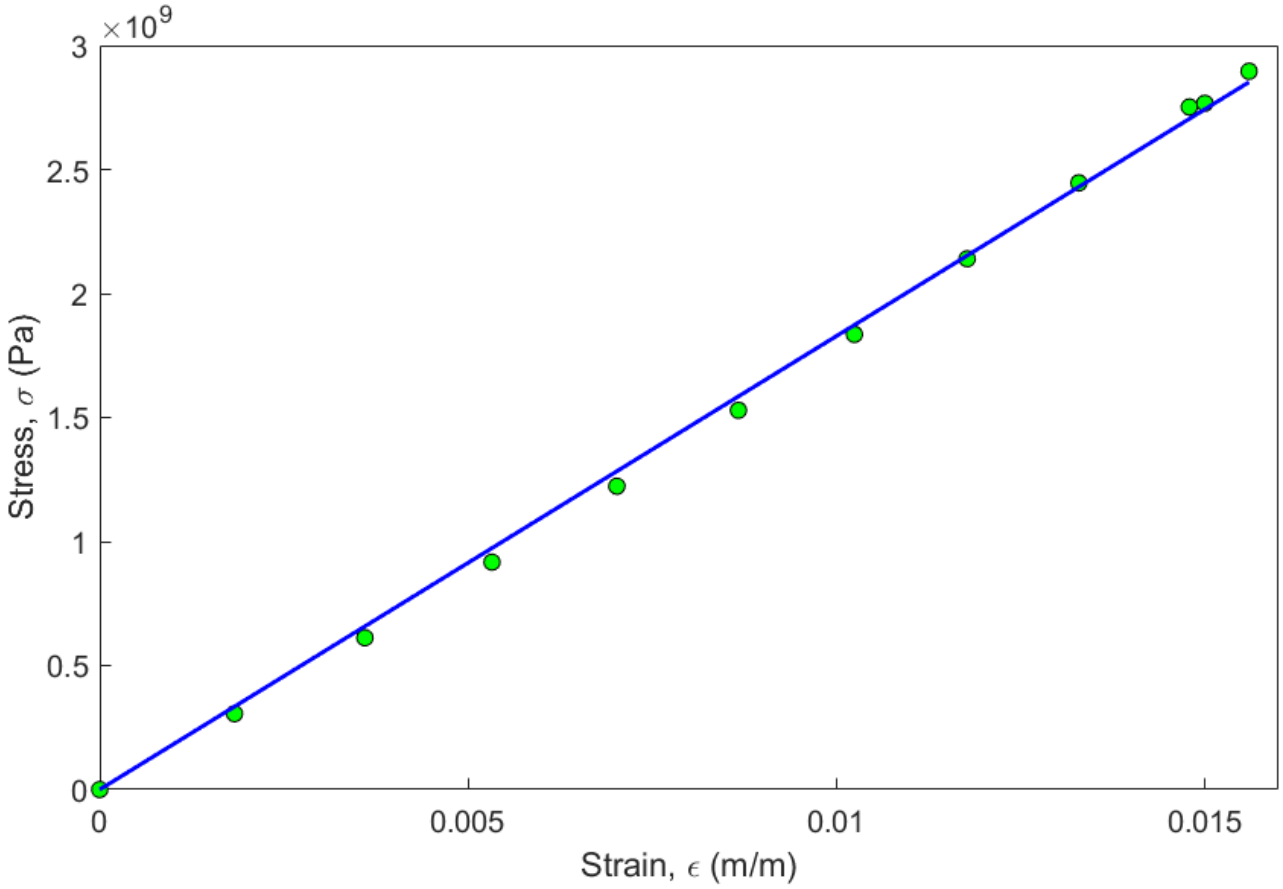

Regresión lineal generalizada

Teniendo que $y = a_0 + a_1 x$ para un conjunto de datos de n puntos. Y recordando que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x)^2$$

Y haciendo un poco de algebra como en el caso anterior, encontramos que

$$a_1 = \frac{S_{xy}}{S_{xx}}; \qquad a_0 = \overline{y} - a_1 \overline{x}$$

donde

$$S_{xy} = \sum_{i=1}^{n} x_i y_i - n\overline{x}\,\overline{y};\ S_{xx} = \sum_{i=1}^{n} x_i^2 - n\overline{x}^2;\ \overline{x} = \frac{\sum_{i=1}^{n} x_i}{n},\ \overline{y} = \frac{\sum_{i=1}^{n} y_i}{n}$$

Ejercicio

Volvamos a este ejercicio. Se mide con instrumentos de laboratorio el torque para diferentes ángulos del resorte de la trampa de ratón y se tiene

Angle	Torque
Radians	N-m
0.698132	0.188224
0.959931	0.209138
1.134464	0.230052
1.570796	0.250965
1.919862	0.313707

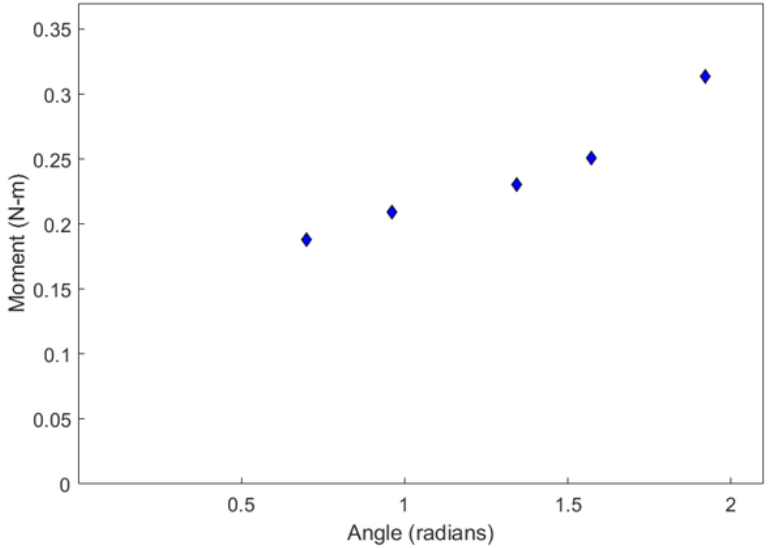

Encuentre las constantes k_1 y k_2 dada la ecuación $T = k_1 + k_2\theta$

Regresión no lineal

Muchos fenómenos físicos presentan una relación no lineal entre variables.

El planteamiento del problema no lineal es el mismo

$$E_i = y_i - f(x_i); \;\; S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - f(x))^2$$

Existen muchos modeos no-lineales básicos en ciencia:

- Modelo exponencial: $f(x) = ae^{bx}$
- Modelo de potencia: $f(x) = ax^b$
- Modelo de crecimiento por saturación: $f(x) = \frac{ax}{b+x}$
- Modelo harmónico descendente: $f(x) = \frac{b}{1+ax}$
- Modelos polinómicos: $f(x) = a_0 + a_1 x + ... + a_m x^m, \;\; m < n$

Ejemplo modelo exponencial

Dado un conjunto de puntos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, tal que el mejor ajuste está dado por ae^{bx}.

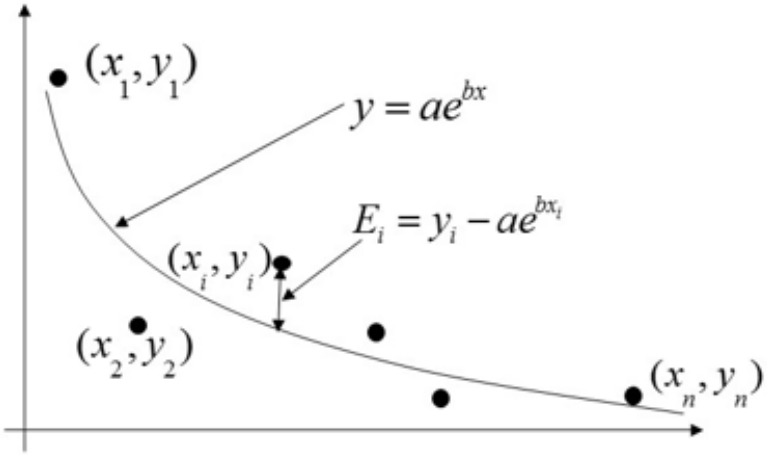

Donde las variables a y b son constantes en el modelo exponencial. E_i son los residuos en cada punto, tal que la suma de los residuos al cuadrado son

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - ae^{bx_i})^2 \tag{5}$$

Para encontrar a y b, minimizamos diferenciando

$$\frac{\partial S_r}{\partial a} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-e^{bx_i}) = -2\sum_{i=1}^{n} y_i e^{bx_i} + 2\sum_{i=1}^{n} e^{2bx_i} = 0$$

$$\frac{\partial S_r}{\partial b} = \sum_{i=1}^{n} 2(y_i - ae^{bx_i})(-ax_i e^{bx_i}) = -2a\sum_{i=1}^{n} x_i y_i e^{bx_i} + 2a^2\sum_{i=1}^{n} x_i e^{2bx_i} = 0$$

Podemos ver que para encontrar a y b. necesitamos resolver un sistema de ecuaciones no lineales, y se requieren métodos numéricos.

Ya que los sistemas lineales son más simples de resolver, es posible transformar algunos modelos no lineales de forma lineal, pero no todos se pueden transformar.

Siguiendo el modelo ae^{bx}, aplicamos el logaritmo natural a ambos lados de la ecuación

$$\ln y = \ln a + bx \tag{6}$$

renombramos $\ln y = z$, $\ln a = a_0$ y $a_1 = b$, entonces tenemos

$$z = a_0 + a_1 x \tag{7}$$

Solucionando a_1 y a_0

$$a_1 = \frac{n\sum_{i=1}^{n} x_i z_i - \sum_{i=1}^{n} x_i \sum_{i=1}^{n} z_i}{n\sum_{i=1}^{n} x_i^2 - \left(\sum_{i=1}^{n} x_i\right)^2}$$

$$a_0 = \overline{z} - a_1\overline{x}$$

tal que $b = a_1$ y $a = e^{a_0}$

Ejemplo aplicado modelo exponencial

Para un scan de la vesicula biliar, , se usa el isotop technetium-99m con un tiempo de vida medio de 6 horas, pero usualmente se hace seguimiento por 24 horas.

time (h)	0	1	3	5	7	9
radiation (γ)	1.0	0.891	0.708	0.562	0.447	0.355

Table: Intensidad de radiación relativa en functión del tiempo

El nivel de intensidad de radiación relativa está relacionado con el tiempo con ecuación $\gamma = Ae^{\lambda t}$.

Usando la transformación de la exponencial

a) evaluar las constantes de regresión A y λ
b) vida media del technetium-99m
c) la intensidad de radión después de 24 horas.

Si no transformamos la función exponencial. Recordemos que

$$\frac{\partial S_r}{\partial a} = -\sum_{i=1}^{n} y_i e^{bx_i} + a \sum_{i=1}^{n} e^{2bx_i} = 0 \tag{8}$$

$$\frac{\partial S_r}{\partial b} = -\sum_{i=1}^{n} x_i y_i e^{bx_i} + a \sum_{i=1}^{n} x_i e^{2bx_i} = 0 \tag{9}$$

De ec. (8) se puede obtener a explicitamente en términos de b

$$a = \frac{\sum_{i=1}^{n} y_i e^{bx_i}}{\sum_{i=1}^{n} e^{2bx_i}} \tag{10}$$

y reemplazando a en ec. (9)

$$\sum_{i=1}^{n} x_i y_i e^{bx_i} - \frac{\sum_{i=1}^{n} y_i e^{bx_i}}{\sum_{i=1}^{n} e^{2bx_i}} \sum_{i=1}^{n} x_i e^{2bx_i} \tag{11}$$

pero sigue sin ser lineal, y debe solucionarse usando métodos númericos, por ejemplo bisección o secante.

Ejercicio en clase

Usando los mismos datos de la tabla, responder las mismas preguntas en el ejemplo.

time (h)	0	1	3	5	7	9
radiation (γ)	1.0	0.891	0.708	0.562	0.447	0.355

Table: Intensidad de radiación relativa en function del tiempo

a) evaluar las constantes de regresión A y λ
b) vida media del technetium-99m
c) la intensidad de radión después de 24 horas.

Ejercicio para entregar

Resolver usando el método de bisección:
La función no lineal para resolver con el método de bisección sería

$$f(\lambda) = \sum_{i=1}^{n} \gamma_i t_i e^{\lambda t_i} - \frac{\sum_{i=1}^{n} \gamma_i e^{\lambda t_i}}{\sum_{i=1}^{n} e^{2\lambda t_i}} \sum_{i=1}^{n} t_i e^{2\lambda t_i} = 0 \tag{12}$$

- los límites de bisección serán el λ calculado en el ejemplo anterior $\pm 0.0\{\text{nc}\}$, donde nc son los últimos 2 dígitos de la cédula de cada uno. Por ejemplo, si $\lambda = -0.11505$, entonce, con los 2 últimos números de mi cédula sería $\lambda \pm 0.082$, tal que $[x_l, x_u] = [-0.19705, -0.03305]$.
- Escriban un código para encontrar los parámetros A y λ con un error de tolerancia de $\sim 10^{-8}$.

Modelos polinomiales

Dado un conjunto de datos $(x_1, y_1), (x_2, y_2), ..., (x_n, y_n)$, usar método de mínimos cuadrados para hacer regresión de los datos a un polinomio de orden m

$$y = a_0 + a_1 x + a_2 x^2 + ... + a_m x^m, \quad m < n \tag{13}$$

Tenemos entonces que

$$S_r = \sum_{i=1}^{n} E_i^2 = \sum_{i=1}^{n} (y_i - a_0 - a_1 x_i - a_2 x_i^2 - ... - a_m x_i^m)^2 \tag{14}$$

Para encontrar las constante $a_0, a_1, ..., a_m$, minimizamos tal que

$$\frac{\partial S_r}{\partial a_0} = \sum_{i=1}^{n} 2(y_i - a_0 - a_1 x_i - ... - a_m x_i^m)(-1) = 0$$

$$\frac{\partial S_r}{\partial a_1} = \sum_{i=1}^{n} 2(y_i - a_0 - a_1 x_i - ... - a_m x_i^m)(-x_i) = 0$$

$$\vdots = \vdots$$

$$\frac{\partial S_r}{\partial a_m} = \sum_{i=1}^{n} 2(y_i - a_0 - a_1 x_i - ... - a_m x_i^m)(-x_i^m) = 0$$

Reescribiendo en forma matricial

$$\begin{bmatrix} n & \sum_{i=1}^{n} x_i & \cdots & \sum_{i=1}^{n} x_i^m \\ \sum_{i=1}^{n} x_i & \sum_{i=1}^{n} x_i^2 & \cdots & \sum_{i=1}^{n} x_i^{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^{n} x_i^m & \sum_{i=1}^{n} x_i^{m+1} & \cdots & \sum_{i=1}^{n} x_i^{2m} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} y_i \\ \sum_{i=1}^{n} x_i y_i \\ \vdots \\ \sum_{i=1}^{n} x_i^m y_i \end{bmatrix}$$

Este sistema de ecuaciones resuleve las constantes $a_0, a_1, a_2, ..., a_m$.

Ejemplo

Encontrar la contracción de un cilindro de acero. Para eso uno hace regresión el coeficiente de expansión térmica lineal con respecto a la temperatura.

temperatura (^oC)	26.6	4.4	-40
coeficiente ($\alpha[1/^oC]$)	11.23×10^{-6}	10.3×10^{-6}	9.16×10^{-6}
temperatura (^oC)	-84.4	-128.9	-173.3
coeficiente ($\alpha[1/^o\mathrm{C}]$)	11.65×10^{-6}	7.74×10^{-6}	5.99×10^{-6}
temperatura (^oC)	-206.7		
coeficiente ($\alpha[1/^o\mathrm{C}]$)	4.41×10^{-6}		

Table: Coeficiente de expansión térmica lineal a diferentes temperaturas

Ajustar los datos anteriores a la función $\alpha = a_0 + a_1 T + a_2 T^2$

Solución

Usando la regresión, a_0, a_1 y a_2 están dados por

$$\begin{bmatrix} n & \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 \\ \sum_{i=1}^{n} T_i & \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 \\ \sum_{i=1}^{n} T_i^2 & \sum_{i=1}^{n} T_i^3 & \sum_{i=1}^{n} T_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{n} \alpha_i \\ \sum_{i=1}^{n} T_i \alpha_i \\ \sum_{i=1}^{n} T_i^2 \alpha_i \end{bmatrix}$$

donde $n = 7$.

Haciendo todas las operaciones, obtenemos la matriz

$$\begin{bmatrix} 7 & -8.6 \times 10^2 & 2.58 \times 10^5 \\ -8.6 \times 10^2 & 2.58 \times 10^5 & -7.0472 \times 10^7 \\ 2.58 \times 10^5 & -7.0472 \times 10^7 & 2.1363 \times 10^{10} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 3.36 \times 10^{-5} \\ -2.6978 \times 10^{-3} \\ 8.5013 \times 10^{-1} \end{bmatrix}$$

Solucionando el sistema de ecuaciones, al final se optiene que $a_0 =?$, $a_1 =?$ y $a_2 =?$

Orden óptimo para una regresión polinomial

Supongamos que no se conocen otros modelos que el polinomial, aún así, uno se enfrenta al problema de qué orden es el más óptimo para ajustar los datos.

Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)	Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)	Temperatura (^oF)	Coeficiente ($\mu(1/^oF)$)
80	6.47	-80	5.43	-240	3.83
60	6.36	-100	5.28	-260	3.58
40	6.24	-120	5.09	-280	3.33
20	6.12	-140	4.91	-300	3.07
0	6.0	-160	4.72	-320	2.76
-20	5.86	-180	4.52	-340	2.45
-40	5.72	-200	4.30		
-60	5.58	-220	4.08		

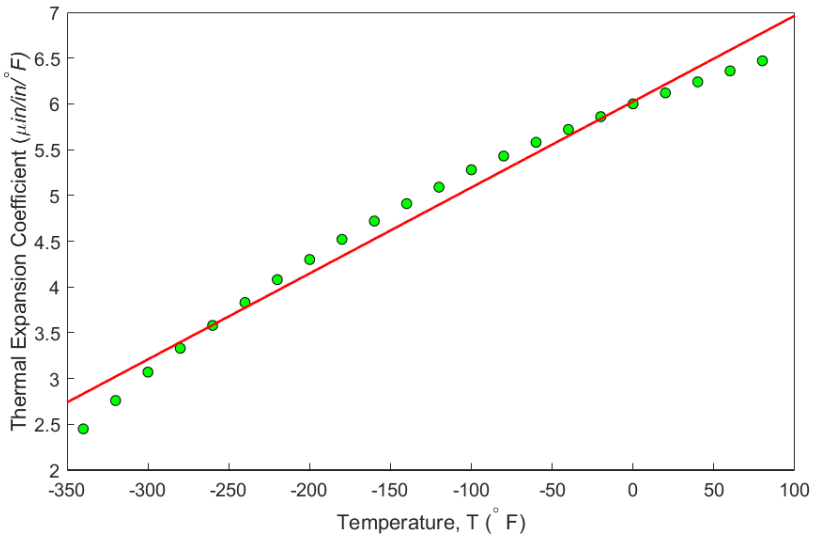

Figure: Regresión polinomial de orden 1 del modelo. $\alpha = 0.00938T + 6.025$

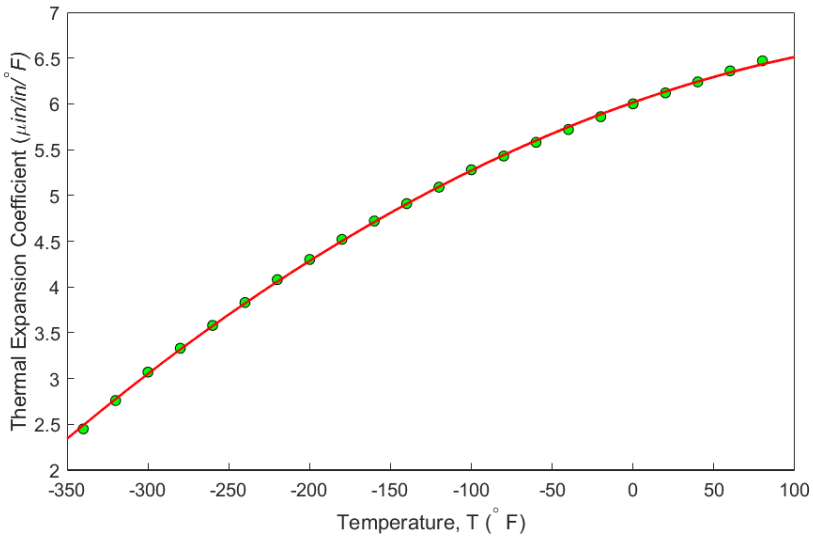

Figure: Regresión polinomial de orden 2 del modelo. $\alpha = -1.228 \times 10^{-5}T^2 + 6.196 \times 10^{-3}T + 6.015$

Aunque visualmente es claro que el polinomio de segundo orden es aceptable, las decisiones deben basarse en medidas cuantificables, en lugar de inspecciones visuales y especulativas.

Uno de los criterios para elegir el grado del polinomio más óptimo, es la variancia dada por

$$\text{variance} = \frac{S_r}{n-(m+1)} \tag{15}$$

Siguiendo este criterio, al final uno sí puede elegir de forma cuantitativa el orden del polinomio

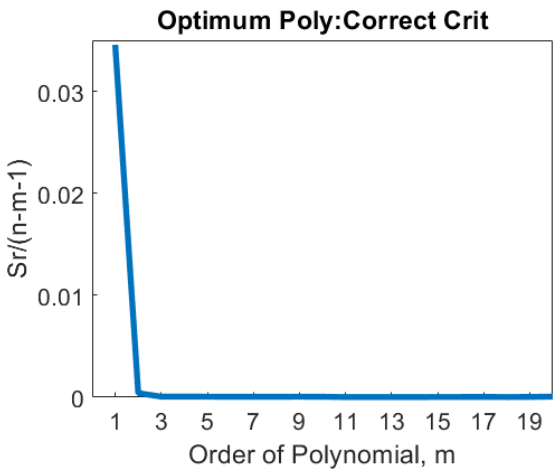

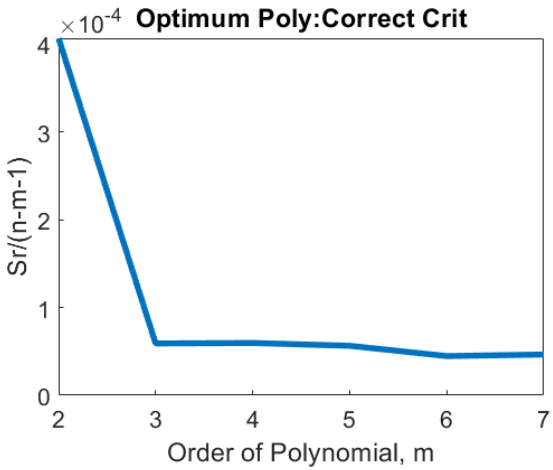

Y aún así, m debería ser 2 o 3?

Continuará

Dr. rer. nat. Jose Ivan Campos Rozo
jicamposr@unal.edu.co